

Analisis Perbandingan Performa Deep Learning: Kustom CNN from Scratch versus Transfer Learning MobileNetV2 untuk Klasifikasi Citra Biner

*Note: Sub-titles are not captured in Xplore and should not be used

line 1: Ahnaf Haidar
line 2: Dept. of Computer Science
/ Teknik Informatika
line 3: University of Darussalam

Gontor
line 4: Ponorogo, Indonesia
line 5: 452024611107

Abstract— This study presents a comparative analysis of two prominent Deep Learning approaches for binary image classification: a custom Convolutional Neural Network (CNN) built from scratch and a Transfer Learning model utilizing a pretrained MobileNetV2 architecture. Using a filtered subset of the CIFAR-10 dataset focusing on "Cats" and "Dogs" (12,000 images), both models were trained under identical constraints for 10 epochs. The dataset was strictly partitioned using stratified sampling into 70% training, 15% validation, and 15% testing sets. Experimental results demonstrate that while the custom CNN provides a lightweight architecture, MobileNetV2 via Feature Extraction delivers vastly superior accuracy and faster convergence, leveraging rich spatial features previously learned from the ImageNet dataset.

Keywords— Deep Learning, Convolutional Neural Network, Transfer Learning, MobileNetV2, CIFAR-10, Image Classification.

I. PENDAHULUAN

Klasifikasi citra digital merupakan salah satu pilar utama dalam perkembangan *Computer Vision*. Seiring berkembangnya teknologi kecerdasan buatan, teknik *Deep Learning* berbasis *Convolutional Neural Network* (CNN) menjadi standar industri dalam mengenali objek visual. Namun, dalam implementasi praktisnya, praktisi sering dihadapkan pada dilema: membangun arsitektur CNN sendiri dari awal (*from scratch*) atau memanfaatkan model raksasa yang sudah dilatih sebelumnya (*Transfer Learning*).

Penelitian ini bertujuan untuk melakukan studi komparatif mendalam mengenai kedua pendekatan tersebut. Fokus eksperimen diarahkan pada klasifikasi biner untuk membedakan objek Kucing dan Anjing menggunakan data yang diekstraksi dari dataset CIFAR-10. Melalui laporan ini, akan dianalisis kelebihan dan kekurangan masing-masing model berdasarkan metrik akurasi, nilai *loss*, jumlah parameter, serta efisiensi waktu latih.

II. DESKRIPSI DATASET DAN PREPROCESSING

A. Deskripsi Dataset

Dataset yang digunakan dalam penelitian ini diturunkan dari dataset publik CIFAR-10. Dataset asli CIFAR-10 memiliki 60.000 gambar berukuran 32×32 piksel yang terbagi ke dalam 10 kelas objek berbeda. Untuk kebutuhan tugas klasifikasi biner (*Cats vs Dogs*), dilakukan proses penyaringan (*filtering*) otomatis secara programatik guna mengekstrak dua kelas spesifik, yaitu kelas Kucing

(Label indeks: 3) dan kelas Anjing (Label indeks: 5). Proses ekstraksi ini menghasilkan total populasi data sebanyak 12.000 gambar biner.

B. Preprocessing dan Pembagian Data

Guna menjamin keabsahan evaluasi ilmiah, dataset biner tersebut dibagi secara ketat menggunakan metode *stratified sampling* ke dalam tiga bagian independen dengan rasio proporsional: 70% Data Training (8.400 gambar) untuk memperbarui bobot internal model, 15% Data Validation (1.800 gambar) untuk memantau indikasi *overfitting* selama proses latih, dan 15% Data Testing (1.800 gambar) sebagai data buta (*unseen data*) untuk pengujian performa akhir.

Tahap *preprocessing* tambahan yang diterapkan meliputi:

1. Normalisasi Skala Piksel: Mengubah nilai mentah matriks gambar $[0, 255]$ menjadi rentang $[0, 1]$ dengan membaginya dengan 255.0k guna menjaga stabilitas gradien dan mempercepat konvergensi optimasi.
2. Penyelarasan Dimensi: Untuk eksperimen *Transfer Learning*, ditambahkan lapisan *Resizing* otomatis guna memperbesar dimensi gambar dari 32×32 piksel menjadi 128×128 piksel agar sesuai dengan batas minimum masukan (*input shape*) dari arsitektur MobileNetV2..

III. IMPLEMENTASI DAN HASIL EKSPERIMEN

A. Implementasi CNN from Scratch

Arsitektur CNN kustom dirancang secara sekuensial dengan susunan sebagai berikut: Lapisan *Conv2D* pertama (32 filter, kernel 3×3 , aktivasi ReLU), diikuti oleh *MaxPooling2D* (2×2) dan lapisan *Dropout* (0.25). Lapisan *Conv2D* kedua ditingkatkan menjadi 64 filter untuk menangkap fitur spasial yang lebih kompleks, ditutup kembali dengan *MaxPooling2D* dan *Dropout* (0.25). Fitur dua dimensi kemudian diratakan menggunakan layer *Flatten*, dialirkan ke *Dense layer* tersembunyi berkapasitas 64 neuron (aktivasi ReLU), dan berakhir pada satu neuron output tunggal beraktivasi *Sigmoid* untuk menghasilkan probabilitas klasifikasi biner.

B. Implementasi Transfer Learning

Identify applicable funding agency here. If none, delete this text box.

Model kedua dibangun menggunakan strategi *Feature Extraction* berbasis arsitektur MobileNetV2 yang telah membawa bobot optimal dari prapelatihan *ImageNet*. Lapisan atas yang bertugas melakukan klasifikasi bawaan dipotong (*include_top=False*). Seluruh lapisan dasar (*base model*) ini dibekukan secara total (*trainable = False*) agar bobot aslinya tidak rusak saat proses latihan. Di atas arsitektur MobileNetV2, disematkan lapisan *GlobalAveragePooling2D*, diikuti oleh satu lapisan *Dense* tersembunyi (64 neuron, ReLU), dan ditutup oleh satu neuron keluaran berbasis fungsi *Sigmoid*.

C. Hasil Eksperimen dan Perbandingan Model

Kedua model dikompilasi menggunakan fungsi *loss* *binary_crossentropy*, pengoptimal *adam*, dan dilatih secara konsisten selama 10 epoch dengan ukuran *batch* sebesar 64. Hasil evaluasi kuantitatif akhir dirangkum pada Tabel I.

TABLE I. TABEL PERBANDINGAN PERFORMA MODEL

Table Column Head		
Metrik Evaluasi	CNN from Scratch	Transfer Learning (MobileNetV2)
Akurasi Training	[Isi nilai akhir Akurasi Train CNN]	[Isi nilai akhir Akurasi Train TL]
Akurasi Validation	[Isi nilai akhir Akurasi Val CNN]	[Isi nilai akhir Akurasi Val TL]
Akurasi Testing	[Isi nilai akhir Akurasi Test CNN]	[Isi nilai akhir Akurasi Test TL]
Loss Testing	[Isi nilai akhir Loss Test CNN]	[Isi nilai akhir Loss Test TL]
Jumlah Parameter	[Isi total parameter CNN]	[Isi total parameter TL]

Analisis grafik performa menunjukkan bahwa CNN *from scratch* mengalami peningkatan akurasi secara bertahap namun memiliki keterbatasan dalam mengenali variasi pola baru, tercermin dari nilai akurasi testing yang lebih rendah. Sebaliknya, grafik *Transfer Learning* menunjukkan kestabilan tinggi dengan lompatan akurasi yang masif sejak epoch pertama. Melalui *Confusion Matrix*, terlihat jelas bahwa MobileNetV2 menghasilkan tingkat salah prediksi (*false positives* dan *false negatives*) yang jauh lebih minim dibandingkan CNN kustom.

^a. Sample of a Table footnote. (Table footnote)

Fig. 1. Example of a figure caption. (figure caption).

IV. ANALISIS TEORETIS DAN STUDI KASUS

a) A. Panduan Memilih CNN vs Transfer Learning Secara teoretis, pemilihan metode klasifikasi citra bergantung

pada dua variabel utama: volume data dan kemiripan domain tugas (domain similarity):

b) Data Sedikit + Domain Mirip: Pilih *Transfer Learning* (*Feature Extraction*) untuk meminimalkan risiko *overfitting*.

c) Data Sedikit + Domain Berbeda: Pilih *Transfer Learning* (*Fine-Tuning*) pada lapisan atas secara hati-hati.

d) Data Banyak + Domain Mirip: Pilih *Transfer Learning* dengan *Fine-Tuning Total* untuk mencapai batas akurasi tertinggi.

e) Data Banyak + Domain Berbeda: Pilihan ideal untuk melatih CNN *from Scratch* karena model memiliki data yang cukup untuk membentuk *representasi* fitur visual unik tanpa bias eksternal.

f) B. Jawaban Studi Kasus Pengambilan Keputusan

g) Skenario 1 (Klinik Medis dengan 300 Gambar): Memilih *Transfer Learning*. Melatih CNN dari awal dengan 300 gambar medis akan memicu *overfitting* parah. Citra medis membutuhkan presisi tinggi. Model pretrained yang sudah memahami geometri bentuk dari jutaan objek *ImageNet* dapat digunakan sebagai pengekstrak fitur dasar, dan klinik cukup melatih lapisan klasifikasi akhir.

h) Skenario 2 (Perusahaan dengan 1 Juta Gambar Produk Unik): Memilih CNN *from Scratch*. Volume data sebesar 1 juta gambar sangat melimpah untuk melatih model dari nol tanpa takut *overfitting*. Karakteristik gambar produk internal yang sangat berbeda dari *ImageNet* membuat bobot prapelatihan tidak relevan, sehingga pembuatan arsitektur mandiri akan menghasilkan model yang jauh lebih sensitif terhadap fitur unik produk internal.

i) Skenario 3 (Prototipe 2 Hari dengan 500 Gambar): Memilih *Transfer Learning* (*Feature Extraction*). Batasan waktu dua hari tidak realistis untuk melakukan pencarian arsitektur (*architecture search*) dan hyperparameter tuning pada CNN dari nol. *Feature Extraction* hanya memerlukan latihan beberapa menit karena hanya memperbarui bobot lapisan kepala klasifikasi, menjadikannya opsi paling rasional.

j) Skenario 4 (Dataset Besar + GPU Memadai + Domain Spesifik): Memilih *Transfer Learning* dengan strategi *Fine-Tuning*. Meskipun memiliki infrastruktur kuat, memulai pelatihan dari bobot acak (*random initialization*) tidak efisien. Memanfaatkan bobot model pretrained sebagai titik start, dilanjutkan dengan membuka beberapa kunci lapisan teratas (*unfreeze*) untuk dilatih kembali dengan *learning rate* sangat kecil, akan menghasilkan konvergensi yang jauh lebih cepat dan akurasi final yang lebih superior.

B. KESIMPULAN DAN REFLEKSI PRIBADI

A. Kesimpulan Eksperimen ini membuktikan keunggulan *Transfer Learning* (MobileNetV2) dalam efisiensi waktu, optimalisasi parameter kerja, dan akurasi tinggi pada keterbatasan data. Walaupun demikian, metode CNN *from scratch* tetap memegang peran penting ilmiah jika dihadapkan pada skenario data berskala masif dengan karakteristik bentuk visual yang sangat terisolasi atau spesifik.

B. Refleksi Pribadi Melalui pengerjaan tugas besar ini, saya memperoleh pemahaman praktis yang mendalam mengenai cara kerja arsitektur jaringan saraf konvolusional. Saya menyadari bahwa membangun model berakurasi tinggi tidak selalu berarti harus melatihnya dari nol. Kemampuan melakukan *engineering* data, menganalisis grafik performa (*overfitting/underfitting*) lewat *validation loss*, serta ketepatan memilih strategi arsitektur berdasarkan batasan sumber daya di dunia nyata (waktu, data, dan komputasi) adalah keahlian krusial yang harus dimiliki oleh seorang praktisi *Machine Learning*.

REFERENCES

- [1] Alex Krizhevsky, "Learning Multiple Layers of Features from Tiny Images," University of Toronto, Tech. Rep., 2009. (*Sumber Dataset CIFAR-10*)
- [2] Mark Sandler, Andrew Howard, Menglong Zhu, Andrey Zhmoginov, and Liang-Chieh Chen, "MobileNetV2: Inverted Residuals and Linear Bottlenecks," in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2018, pp. 4510-4520. (*Referensi Model Transfer Learning*)
- [3] Martin Abadi et al., "TensorFlow: Large-Scale Machine Learning on Heterogeneous Systems," 2015.

B. Refleksi Pribadi

V. 1) Apa tantangan terbesar saat mengerjakan tugas ini?

- [4] Tantangan terbesar adalah saat melakukan *data engineering* di awal. Saya harus memfilter dataset CIFAR-10 secara manual lewat kode agar hanya mengambil kelas kucing (label 3) dan anjing (label 5). Memastikan pembagian data dengan *stratified sampling* (70:15:15) benar-benar seimbang juga cukup menyita waktu agar proses validasinya adil.

VI.2) Bagian mana yang paling sulit: CNN *from scratch* atau *transfer learning*? Mengapa?

- [5] Jelas CNN *from scratch*. Saya harus banyak melakukan *trial-and-error* untuk menentukan arsitektur sendiri dari nol. Menentukan jumlah *layer*, ukuran *filter*, letak *MaxPooling*, hingga mengatur nilai *Dropout* agar model tidak *overfitting* itu sangat membingungkan dibanding *transfer learning* yang arsitekturnya sudah matang tinggal pakai.

VII. 3) Apa perbedaan paling terasa antara melatih model dari awal dan menggunakan *pretrained model*?

- [6] Perbedaan paling terasa ada pada **kecepatan dan stabilitas akurasi**. Model *from scratch* grafiknya merangkak sangat lambat dari bawah karena memulai dari bobot acak. Sedangkan *transfer learning* (MobileNetV2), sejak epoch pertama akurasi langsung melesat tinggi karena modelnya sudah punya "modal pintar" dari jutaan gambar ImageNet.

VIII. 4) Jika tugas ini digunakan untuk kasus nyata, pendekatan mana yang akan Anda pilih?

- [7] Saya akan memilih **Transfer Learning**. Di dunia nyata, kita dituntut efisien dalam hal waktu, biaya sewa GPU, dan keterbatasan data. *Transfer learning* adalah solusi paling pragmatis karena hemat waktu training namun hasilnya sangat akurat. CNN *from scratch* baru saya pilih jika data di industri tersebut sangat unik atau aneh.

IX.5) Apa hal baru yang Anda pelajari tentang pengambilan keputusan dalam *deep learning*?

- [8] Saya sadar bahwa model yang paling kompleks atau melatih dari nol tidak selalu menjadi keputusan terbaik. Pemilihan metode harus disesuaikan dengan kompromi antara **jumlah data, kemiripan objek, dan waktu yang tersedia**. Tugas seorang *engineer* bukan cuma jago ngoding, tapi harus pintar membaca situasi agar efisien.